

Trading Sistemático de Temperatura Máxima

Documentação técnica e guia de estudo — SBGR, SAEZ, UUWW e mais

Pipeline `tmax/` — mercados de temperatura na Polymarket

Números do backtest atualizados em 2026-07-13 20:48:50 UTC

Resumo

Este documento descreve, com a matemática e a estatística por trás, como o pipeline transforma previsões meteorológicas em decisões de trade em mercados binários de temperatura máxima, e como validamos essas decisões com backtests. É também um guia de estudo: cada seção termina com exercícios (gabarito no apêndice). **Não é aconselhamento financeiro** — mercados de previsão envolvem risco de perda total do capital, e o *edge* estimado aqui é um modelo, não uma garantia.

Sumário

1	Visão geral	2
2	Da previsão à distribuição	2
2.1	Por que ensemble	2
2.2	Correção de vies (<code>bias.py</code>)	2
2.3	Nowcast intradiário	2
2.4	Mistura de gaussianas	3
3	Do modelo ao mercado	3
3.1	Faixas, arredondamento e unidades	3
3.2	Edge e valor esperado	3
4	Calibração — o coração estatístico	4
4.1	Regressão isotônica (PAVA)	4
4.2	O <i>blend</i> com o preço (diagnóstico)	4
5	Estratégias operacionais	4
5.1	Estratégia <i>Edge</i>	4
5.2	Estratégia <i>Colheita de favoritos</i>	4
5.3	Stop loss	5
5.4	Como os alertas chegam ao vivo (produção)	5
6	Backtest — metodologia e resultados atuais	5
6.1	Metodologia	5
6.2	Resultados (arquivo de 1610 dias-cidade, ~89 dias corridos)	6
7	Gestão de risco	6
A	Gabarito	6

1 Visão geral

O objetivo é comparar, para cada faixa de um mercado do tipo “a máxima de hoje vai ser $N^{\circ}\text{C}^{\circ}$ ”, a nossa probabilidade estimada com a probabilidade implícita pelo preço, e agir quando as duas divergem o suficiente e o modelo está calibradamente confiante.

O sistema tem três camadas:

1. **Previsão** (Seção 2): ensembles numéricos + correção de viés + observações em tempo real → uma *distribuição de probabilidade* da máxima do dia.
2. **Precificação e calibração** (Seções 3 e 4): a distribuição vira probabilidade por faixa de mercado, corrigida por uma curva de calibração empírica.
3. **Estratégia e risco** (Seções 5 e 7): quando comprar, quanto apostar, quando sair.

Hoje o sistema é *somente-leitura*: monitora 18 cidades, manda alertas ao Telegram e mede tudo com backtests; a ordem na Polymarket é executada manualmente. Estações que resolvem em Fahrenheit foram catalogadas mas ficam fora de operação.

Exercício 1.1. Num binário, o preço do “Sim” (entre 0 e 1) é interpretado como a probabilidade que o mercado atribui ao evento. Se o “Sim” custa \$0,40, qual a probabilidade implícita do “Não”?

2 Da previsão à distribuição

2.1 Por que ensemble

Um modelo de tempo é um sistema caótico: erros minúsculos na condição inicial crescem exponencialmente. Um *ensemble* roda o mesmo modelo várias vezes com perturbações na condição inicial (ECMWF ENS: 51 membros; GEFS: 31). Cada membro é uma amostra do futuro possível; a fração de membros acima de um limiar estima a probabilidade de excedê-lo. Usamos ~82 membros.

2.2 Correção de viés (bias.py)

Modelos globais têm erro sistemático num ponto específico. Estimamos, por família de modelo m , ao longo dos últimos 60 dias:

$$\text{viés}_m = \frac{1}{n} \sum_{d=1}^n [\hat{T}_m(d) - T_{\text{obs}}(d)], \quad n \geq 15, \quad (1)$$

$$\sigma_m^{\text{res}} = \sqrt{\frac{1}{n-1} \sum_{d=1}^n [\hat{T}_m(d) - T_{\text{obs}}(d) - \text{viés}_m]^2}. \quad (2)$$

A previsão corrigida é $\hat{T}_m - \text{viés}_m$; o desvio residual σ_m^{res} é o erro que *sobra* e vira o σ do membro na mistura (Seção 2.4).

2.3 Nowcast intradiário

Durante o dia, o observado pesa mais que o modelo. Medimos o desvio médio entre o METAR e a média do ensemble corrigido nas últimas 3 horas e deslocamos as horas restantes por uma fração amortecida:

$$\text{offset} = \text{mean}_{\text{últ. 3h}} [T_{\text{obs}}(h) - \bar{T}_{\text{ens}}^{\text{corr}}(h)], \quad \text{shift} = 0,7 \cdot w(h) \cdot \text{offset}, \quad (3)$$

com $w(h) = \text{clamp}(\frac{h-6}{6}, 0,25, 1)$. O fator 0,7 evita perseguir ruído; $w(h)$ reduz o peso da madrugada, quando nevoeiro e inversão térmica enganam.

2.4 Mistura de gaussianas

Para cada membro i , a máxima corrigida do dia é $\hat{T}_i = \max(\text{obs_max}, \max_h[\text{horas futuras corrigidas}] + \text{shift})$. A distribuição da máxima é a *média* das CDFs (mistura com pesos iguais):

$$F(x) = \Pr(T_{\max} \leq x) = \frac{1}{M} \sum_{i=1}^M \Phi\left(\frac{x - \hat{T}_i}{\sigma_i}\right), \quad \sigma_i = \max(\sigma_{\text{fam}(i)}^{\text{res}} \cdot f_{\text{rest}}, 0, 3), \quad (4)$$

com $f_{\text{rest}} = \text{clamp}(\frac{17-h}{12}, 0, 2, 1)$ — a incerteza encolhe à tarde. Duas cirurgias que os backtests motivaram:

- **Truncagem:** $F(x) = 0$ para $x < \text{obs_max}$ — a máxima nunca fica abaixo do já observado.
- **Trava:** quando o pico *observado* já passou (3 horas seguidas abaixo da máxima) e nenhuma hora futura chega perto, σ_i colapsa para 0,05. Exige a trava *observacional* — colapsar por previsão (o ensemble “achando” que a tarde não esquenta) gerava certezas falsas de manhã.

Os quantis (P10/P50/P90) saem por bissecção sobre F .

Exercício 2.1. O viés do ECMWF em Guarulhos é $-0,7^\circ\text{C}$ e o modelo prevê máxima de $24,0^\circ\text{C}$. Qual a previsão corrigida? Se $\sigma^{\text{res}} = 0,9$ e $f_{\text{rest}} = 1$, qual o σ do membro? **Exercício 2.2.**

Mistura de dois membros, $\mathcal{N}(25, 1)$ e $\mathcal{N}(27, 1)$. Calcule $\Pr(T_{\max} \leq 26)$ usando $\Phi(1) = 0,841$ e $\Phi(-1) = 0,159$.

3 Do modelo ao mercado

3.1 Faixas, arredondamento e unidades

O mercado resolve pela máxima *arredondada ao inteiro* na unidade da cidade. A faixa “ $N^\circ\text{C}$ ” cobre $[N - 0,5, N + 0,5)$; “entre $A-B^\circ\text{F}$ ” cobre $[A - 0,5, B + 0,5)$ em Fahrenheit. Como a distribuição interna é em $^\circ\text{C}$, faixas em $^\circ\text{F}$ são convertidas nas *bordas*: $c(f) = (f - 32) \cdot 5/9$. A probabilidade da faixa $[A, B]$ é

$$\Pr(\text{Sim}) = F(c(B + 0,5)) - F(c(A - 0,5)). \quad (5)$$

3.2 Edge e valor esperado

Num binário, o preço do Sim é a probabilidade implícita q . Pagando q num evento com probabilidade real p :

$$\text{EV por \$1} = p \cdot \left(\frac{1}{q} - 1\right) - (1 - p) = \frac{p - q}{q}. \quad (6)$$

O *edge* em pontos percentuais é $p - q$. O EV relativo cresce quando q é pequeno — por isso “bilhetes de loteria” baratos dominam o P&L de backtests ingênuos e merecem desconfiança (preço fino não executa).

Exercício 3.1. Mercado NYC “entre $78-79^\circ\text{F}$ ”. Converta as bordas da faixa para $^\circ\text{C}$. **Exercício**

3.2. Você compra o “Não” a $\$0,85$ e sua probabilidade calibrada do “Não” é 94%. Calcule o edge (p.p.) e o EV por $\$1$.

4 Calibração — o coração estatístico

Um modelo é *calibrado* se, entre os casos em que diz 90%, o evento ocorre $\sim 90\%$ das vezes. Medimos com o *Brier score* (erro quadrático médio da probabilidade; menor é melhor):

$$\text{Brier} = \frac{1}{n} \sum_{i=1}^n (p_i - y_i)^2, \quad y_i \in \{0, 1\}. \quad (7)$$

Diagnóstico sobre ~ 120 mil pares previsão–desfecho: o modelo cru declara $\sim 99\%$ mas acerta entre 84% e 92% nas faixas-dia com confiança $\geq 90\%$ (varia por cidade) — superconfiança nas caudas.

4.1 Regressão isotônica (PAVA)

Ajustamos g monótona não-decrescente minimizando $\sum (g(p_i) - y_i)^2$ pelo algoritmo *Pool Adjacent Violators*: percorre os pares ordenados por p e funde blocos vizinhos enquanto a média de um bloco anterior for $\geq$ à do seguinte. Resultado: um mapa “probabilidade dita $\rightarrow$ frequência real”, por *período do dia* (0–5h / 6–11h / 12–23h), porque a superconfiança da madrugada (pouca observação) é muito maior que a da tarde.

4.2 O *blend* com o preço (diagnóstico)

Uma regressão logística $y \sim a \text{logit}(p_{\text{modelo}}) + b \text{logit}(\text{preço}) + c$, por período, mede quem carrega informação: de madrugada $a \approx 0$ (o modelo não adiciona nada ao preço); à tarde $a > 0$ (adiciona). Decisão operacional: os sinais usam só o modelo calibrado (o mesmo número da tabela); o *blend* segue como diagnóstico.

Exercício 4.1. O modelo declara 99% em 842 faixas-dia e acerta 86%. Qual o Brier aproximado dessas previsões? (aproxime $p = 0,99$ e frequência 0,86.) **Exercício 4.2.** PAVA: pares ordenados

por p com desfechos $y = [0, 1, 0, 1, 1]$. Quais os blocos e os valores finais da isotônica?

5 Estratégias operacionais

5.1 Estratégia *Edge*

Compra o “Não” de uma faixa de hoje quando:

- $|p_{\text{cal}} - q| \geq 5$ p.p. (divergência mínima);
- o lado “Não” tem $> 90\%$ de chance segundo o modelo calibrado;
- preço do “Não” $\geq \$0,30$ (não brigar com mercado quase-certo);
- hora local entre 6h e 23h; cruzamento novo (madrugada é descartada).

Só o lado “Não” é operado: o “Sim” teve $\sim 41\%$ de acerto (loteria). Testamos e *rejeitamos* um teto de *edge* de 20 p.p.: no lado “Não” já filtrado, gaps grandes são o modelo vendo a máxima da tarde antes do mercado convergir, não erro.

5.2 Estratégia *Colheita de favoritos*

Compra o “Não” quase-certo (preço entre $\$0,97$ e $\$0,995$), após as 16h locais, com o modelo concordando. Depois desse horário a máxima está praticamente travada e o favorito a 97 centavos é quase-matemática. Colhe os últimos centavos de incerteza residual.

5.3 Stop loss

Num binário o preço *é* a probabilidade: cair 15% significa que o mercado agora acha o evento 15% menos provável. O stop converte a perda potencial total (−100%) numa perda pequena e certa (−15%), ao custo de realizar ruído. Vale quando o gatilho é *informativo* (o dado virou — a máxima estourou a faixa) e custa caro quando é só volatilidade.

Exercício 5.1. Você entra a \$0,70; o alerta dispara a −10% e a saída do backtest a −15%. Em que preços cada um dispara? Se o evento venceria na resolução, quanto o stop custou por \$1 de stake?

5.4 Como os alertas chegam ao vivo (produção)

O backtest conta *entradas* (uma por faixa/dia, no primeiro cruzamento); o que chega ao Telegram segue regras de *entrega* diferentes:

- **Modo silencioso:** o chat recebe só alertas (compra, colheita, condição, stop) e o resumo de posições no máximo 1× por hora.
- **Alerta de compra novo:** chega com o *bloco completo* da cidade (tabela, gráfico, hora a hora) — o contexto da decisão de entrada. Você também pode pedir o relatório de qualquer cidade a qualquer momento por `/relatorio`.
- **Repetição:** *edge* e colheita repetem a cada rodada (~10 min) enquanto a oportunidade durar; as repetições vêm sozinhas em texto curto (sem repetir os gráficos). Uma entrada equivale a muitas mensagens.
- **Alertas de condição** (só cidades com posição aberta): platô de 2h de lado e fuga do envelope do *ensemble* — uma vez por episódio.
- **Stop:** dispara a −10% do preço de entrada e repete toda rodada; a saída de referência do backtest é −15%.

Ao vivo dispara mais que o backtest. O backtest só considera faixas com negócio recente ($\leq 2h$); ao vivo o alerta usa o preço nominal exibido, e por isso também dispara em faixas ilíquidas que o backtest descarta. Medido no arquivo atual, são ~18% mais sinais ao vivo do que a simulação reporta — não é erro, são medições diferentes. Além disso, num único dia os sinais se *acumulam* no chat (cada cidade no seu fim de tarde local), enquanto o backtest os distribui por data: por isso um dia com 3–4 sinais parece muito, mas ainda é um evento raro (o histórico teve no máximo 4 num único dia).

6 Backtest — metodologia e resultados atuais

6.1 Metodologia

Para cada dia arquivado reconstruímos, hora a hora, o que o sistema atual teria dito: viés “como era” (janela de 60 dias terminando 2 dias antes), METARs até a hora h , ensemble arquivado, nowcast, mistura $\rightarrow$ probabilidade por faixa; preço = último negócio (máx. 2h de idade); resolução = desfecho oficial. Aposta de 10% do capital no primeiro cruzamento da regra, liquidada na resolução (ou no stop de −15%). **Flat** usa sempre 10% do capital *inicial* (para comparar regras); **composto** reinveste 10% do capital *corrente* (o “quanto eu teria”).

Vieses conhecidos. *Lookahead* do ensemble arquivado (otimista); *liquidez* (o último preço de mercado fino não executa em tamanho); *in-sample* (a calibração é ajustada no mesmo período — mitigada pelo reajuste a cada 3 dias, com dias novos entrando *depois* do ajuste).

6.2 Resultados (arquivo de 1610 dias-cidade, ~89 dias corridos)

Estratégia	Entradas	Acerto	Composto	DD máx	Stops
Edge (Não, simulação histórica)	43	93%	2.30 x	2%	4
Colheita 16h	152	100%	1.14 x	2%	2
Colheita 14h	386	99%	1.30 x	6%	10
Colheita 12h	605	99%	1.53 x	6%	16
Combinado (Edge + Colheita 16h)	195	98%	2.53 x	3%	6

Retorno composto do portfólio combinado, anualizando a janela de ~89 dias para base mensal: **+37% ao mês** (in-sample; a expectativa executada realista é mais modesta, tipicamente 10–20%/mês, por causa de liquidez e slippage). Preço médio pago pela Edge: \$0.82.

Estes números são regenerados automaticamente a cada backtest (2026-07-13 20:48:50 UTC) — veja `backtest_results/` e `generated_numbers.tex`.

Exercício 6.1. A estratégia Edge fez 43 entradas em ~89 dias. Isso é o número de alertas que você recebeu? Explique a diferença entre “entradas simuladas” e “mensagens recebidas”.

7 Gestão de risco

Kelly para um binário comprado a q com probabilidade real p :

$$f^* = \frac{p - q}{1 - q} \quad (\text{fração da banca; aposte } 0 \text{ se } p \leq q). \quad (8)$$

Kelly maximiza o crescimento logarítmico *mas* assume p exato — e a Seção 4 mostrou que nosso p tem erro. Regra da casa: $\frac{1}{4}$ de Kelly, teto de 5% por mercado, 10–15% somando o dia/cidade (faixas do mesmo dia são *uma* aposta), e *circuit breaker* de drawdown mensal.

Exercício 7.1. Kelly: $p = 0,90$, preço $q = 0,80$. Calcule f^* e $\frac{1}{4}$ de Kelly. Com banca de \$2.000, quanto apostar (respeitando o teto de 5%)?

A Gabarito

1.1 $1 - 0,40 = 0,60 = 60\%$.

2.1 $24,0 - (-0,7) = 24,7^\circ\text{C}$; $\sigma = \max(0,9 \cdot 1; 0,3) = 0,9$.

2.2 $F(26) = \frac{1}{2}[\Phi(1) + \Phi(-1)] = \frac{1}{2}(0,841 + 0,159) = 0,50$.

3.1 $c(77,5) = (77,5 - 32) \cdot 5/9 = 25,28^\circ\text{C}$; $c(79,5) = 26,39^\circ\text{C}$. Faixa $[25,28; 26,39)$.

3.2 Edge = $94 - 85 = 9$ p.p.; EV = $(0,94 - 0,85)/0,85 = +10,6\%$ por \$1.

4.1 Brier $\approx 0,86 \cdot (0,99 - 1)^2 + 0,14 \cdot (0,99 - 0)^2 \approx 0,137$ (contra $\sim 0,01$ se calibrado).

4.2 $[1, 0]$ viola $\rightarrow$ funde em 0,5. Valores finais: 0; 0,5; 0,5; 1; 1.

5.1 Alerta a $0,70 \cdot 0,90 = \$0,63$; saída a $0,70 \cdot 0,85 = \$0,595$. Num vencedor você recebeu 0,85 em vez de $1/0,70 = 1,43$ por \$1 de stake $\Rightarrow$ deixou $\sim 0,58$ na mesa.

6.1 NÃO é contagem de alertas. “Entradas simuladas” = quantas vezes a regra teria comprado reencenando o histórico; “mensagens recebidas” inclui as repetições a cada 10 min enquanto a oportunidade dura (uma oportunidade = muitas mensagens).

7.1 $f^* = (0,90 - 0,80)/(1 - 0,80) = 0,50$; $\frac{1}{4}$ Kelly = 12,5% $\Rightarrow$ \$250, mas o teto de 5% limita a \$100.